

Sztuczna Inteligencja

Wykład 5: Systemy uczące się

Dominik Ślęzak

Wydział Matematyki, Informatyki i Mechaniki UW
slezak@mimuw.edu.pl



Uczenie indukcyjne

Obiekty:

dane reprezentujące rzeczywisty stan lub obiekt, tworzą przestrzeń obiektów X

Decyzja:

Funkcja $d : X \rightarrow V_d$ przypisująca obiektom wartość decyzji z ustalonego zbioru V_d

Zbiór przykładów:

ustalony zbiór obiektów z X z przypisanymi wartościami decyzji:
 $(x_1, d(x_1)), \dots, (x_m, d(x_m))$

Problem:

Z danego zbioru przykładów nauczyć się funkcji (hipotezy) $h : X \rightarrow V_d$ aproksymującej decyzję d tak, żeby możliwie najbardziej poprawnie przypisywała ją obiektom z przestrzeni X , dla których nieznana jest wartość decyzji



Uczenie indukcyjne: przykład

Obiekty to wektory wartości opisujące bieżące warunki pogodowe

Przykład	Atrybuty						Decyzja
	<i>Niebo</i>	<i>Temp</i>	<i>Wilgotn</i>	<i>Wiatr</i>	<i>Woda</i>	<i>Prognoza</i>	<i>Sport</i>
Dzień 1	Słońce	Ciepło	Normalna	Silny	Ciepła	Bez zmian	Tak
Dzień 2	Słońce	Ciepło	Wysoka	Silny	Ciepła	Bez zmian	Tak
Dzień 3	Deszcz	Zimno	Normalna	Silny	Ciepła	Zmiana	Nie
Dzień 4	Słońce	Ciepło	Wysoka	Silny	Chłodna	Zmiana	Tak

Problem polega na nauczaniu się podejmowania właściwego wyboru na podstawie bieżących warunków pogodowych.



Rodzaje decyzji i atrybuty

Decyzja może przyjmować wartości:

- rzeczywiste (decyzja ciągła)
- dyskretne
- binarne (*TRUE* lub *FALSE*)
- złożone

Atrybuty: zbiór atrybutów $A = \{a_1, a_2, \dots, a_n\}$

Obiekty: Wektory wartości atrybutów $x = \langle x_1, x_2, \dots, x_n \rangle$

Wartości atrybutów mogą być:

- ciągłe
- dyskretne
- binarne (*TRUE* lub *FALSE*)



Przestrzeń hipotez

Ile jest różnych hipotez (funkcji) binarnych dla n atrybutów binarnych?

= liczba funkcji binarnych dla dziedziny z 2^n obiektami = 2^{2^n}

np. dla 6 atrybutów binarnych jest 18.446.744.073.709.551.616 hipotez

Ograniczanie przestrzeni hipotez:

Przestrzeń hipotez można ograniczyć do ustalonej klasy hipotez

Ile jest czysto koniunkcyjnych funkcji (np. $Hungry \wedge \neg Rain$)?

Każdy atrybut może wystąpić jako tzw. literał pozytywny, negatywny lub wcale

$\Rightarrow 3^n$ różnych funkcji koniunkcyjnych

Zwiększanie przestrzeni hipotez

Co daje zwiększenie klasy dopuszczalnych hipotez?

- zwiększa szansę, że funkcja docelowa może być wyrażona
- zwiększa liczbę hipotez zgodnych ze zbiorem treningowym

$\Rightarrow$ może spowodować gorszą skuteczność predykcji



Empiryczna miara jakości hipotezy

Dane dzielone są na zbiór treningowy U_{trn} i zbiór testowy U_{tst}

Hipoteza $h : X \rightarrow V_d$ jest indukowana na podstawie zbioru treningowego U_{trn}


Skuteczność hipotezy $Accuracy(h)$ jest mierzona proporcją poprawnie sklasyfikowanych obiektów ze zbioru testowego

$$Accuracy(h) = \frac{|\{x \in U_{tst} : h(x) = d(x)\}|}{|U_{tst}|}$$




Regresja (decyzja ciągła)

Regresja to aproksymacja decyzji o wartości ciągłej



Regresja liniowa




Regresja kwadratowa




Regresja (decyzja ciągła)

Regresja to aproksymacja decyzji o wartości ciągłej



Regresja wyższego stopnia (spójna)



Regresja kawałkami liniowa (spójna)



Modele decyzyjne

Metody wnioskowania dla danych opisanych przez zbiór atrybutów z decyzją dyskretną:

- Drzewa decyzyjne
- Sieci neuronowe
- (...)



Drzewa decyzyjne: reprezentacja

Węzły wewnętrzne

Każdy związany z jednym atrybutem,
reprezentuje test wartości tego atrybutu

Gałęzie

Każda związana z jedną wartością lub z podzbiorem wartości atrybutu
węzła, z którego wychodzi gałąź,
odpowiada obiektom danych z pasującymi wartościami atrybutu

Liście

Każdy związany z decyzją lub rozkładem decyzji,
odpowiada obiektom danych pasującym do ścieżki prowadzącej do
danego liścia




Drzewa decyzyjne: przykład

Reprezentacja danych

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No



Drzewa decyzyjne: przykład



Drzewa decyzyjne: moc wyrażania


Fakt 1: Dla każdego zbioru treningowego istnieje spójne drzewo decyzyjne

Dowód: zaczynamy od pustego drzewa i dla każdego obiektu danych dokładamy ścieżkę prowadzącą przez wszystkie atrybuty z wartościami krawędzi odpowiadającymi wartościom atrybutów w obiekcie

Fakt 2: Dla każdej funkcji istnieje spójne drzewo decyzyjne

Dowód: można utworzyć zbiór treningowy zawierający obiekty odpowiadające wszystkim kombinacjom wartości atrybutów o decyzji zgodnej z daną funkcją

A	B	A xor B
F	F	F
F	T	T
T	F	T
T	T	F



Drzewa decyzyjne: trenowanie

Cel: znalezienie drzewa spójnego ze zbiorem treningowym



Pomysł: rekurencyjne wybieranie najbardziej znaczącego atrybutu jako korzenia poddrzewa

```
function DTL(examples, attributes, default) returns a decision tree
  if examples is empty then
    return default
  else if all examples have the same classification then
    return the classification
  else if attributes is empty then
    return MODE(examples)
  else
    best  $\leftarrow$  CHOOSE-ATTRIBUTE(attributes, examples)
    tree  $\leftarrow$  a new decision tree with root test best
    for each value  $v_i$  of best do
      examplesi  $\leftarrow$  { elements of examples with best =  $v_i$  }
      subtree  $\leftarrow$  DTL(examplesi, attributes – best, MODE(examples))
      add a branch to tree with label  $v_i$  and subtree subtree
    end for
    return tree
  end if
end function
```



Drzewa decyzyjne: wybór atrybutu

Różne atrybuty dają różne rozkłady decyzji w gałęziach



Funkcja CHOOSE-ATTRIBUTE wybiera najlepszy z nich



Entropia

Dany jest rozkład prawdopodobieństwa $\langle p_1, \dots, p_n \rangle$

Miara entropii wyznacza, ile informacji niesie z sobą ten rozkład

$$Entropy(\langle p_1, \dots, p_n \rangle) = \sum_{i=1}^n -p_i \log_2 p_i$$

S — zbiór obiektów danych

S_v — zbiór obiektów w S z decyzją $d = v$

$$Entropy(S) = \sum_{v \in V_d} -\frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}$$

Entropia = średnia liczba bitów potrzebna do zakodowania decyzji dla losowo wybranego obiektu ze zbioru S (przy optymalnym kodowaniu decyzji)

Dlaczego?

Optymalne kodowanie przydziela $-\log_2 p$ bitów do decyzji występującej z prawdopodobieństwem p




Entropia: dwie decyzje

Dane są dwie decyzje: pozytywna ($\oplus$) i negatywna ($\ominus$)

$p_{\oplus} = \frac{|S_{\oplus}|}{|S|}$ — proporcja obiektów z decyzją pozytywną w zbiorze S

$p_{\ominus} = \frac{|S_{\ominus}|}{|S|}$ — proporcja obiektów z decyzją negatywną w zbiorze S

$$Entropy(S) = -p_{\oplus} \log_2 p_{\oplus} - p_{\ominus} \log_2 p_{\ominus}$$




Zysk informacji dla atrybutu symbolicznego

Zysk informacji

$Gain(S, a)$ = redukcja entropii przy podziale zbioru względem atrybutu a

S_v – zbiór obiektów w S z wartością atrybutu $a = v$

$$Gain(S, a) = Entropy(S) - \sum_{v \in Values(a)} \frac{|S_v|}{|S|} Entropy(S_v)$$



Drzewo decyzyjne w każdym węźle wybiera atrybut a z największym zyskiem informacji, tzn. z największą wartością $Gain(S, a)$.



Inne sposoby wyrażania zysku

Zamiast entropii można stosować na przykład:

- Funkcję zliczającą słusznie rozróżniane przypadki
- (...)

Stawiając sobie za cel tworzenie drzew binarnych można:

- Dokonywać dyskretyzacji atrybutów numerycznych
- Dokonywać grupowania wartości atrybutów symbolicznych

Przykłady przedmiotów, na których można dowiedzieć się więcej:

- Data mining (1000-2M03DM)
- Eksploracja i przetwarzanie dużych zbiorów danych (1000-2M13DZD)



Teoria zbiorów przybliżonych

◇ Zbiory przybliżone (Pawlak, 1981)

◇ Redukty i reguły generowane z reduktów (Skowron, Rauszer, 1992)

$A = \{a_1, \dots, a_n\}$ – zbiór cech (atrybutów) opisujących przykłady

U_{trn} – zbiór przykładów opisanych wektorami wartości cech $\langle x_1, \dots, x_n \rangle$

Definicja

Zbiór atrybutów $R \subseteq A$ jest reduktem dla zbioru przykładów U_{trn} , jeśli

- dla każdej pary przykładów $x, y \in U_{trn}$ o różnych decyzjach $d(x) \neq d(y)$ istnieje $a_i \in R$ rozróżniający tę parę przykładów: $x_i \neq y_i$
- R jest minimalnym zbiorem mającym powyższą własność, tzn. dla dowolnego $R' \subset R$ istnieje para przykładów w U_{trn} o różnych decyzjach i takich samych wartościach na wszystkich atrybutach $a_i \in R'$



Redukty

Definicja

Redukt R jest minimalny, jeśli zawiera najmniejszą możliwą liczbę atrybutów, tzn. dla każdego reduktu R' : $|R| \leq |R'|$

Fakt: Problem znalezienia minimalnego reduktu jest NP-trudny

Przykład:

	a_1	a_2	a_3	a_4	d
x_1	0	2	1	0	0
x_2	1	2	2	1	0
x_3	2	0	2	1	1
x_4	0	2	1	1	2

Redukty: $\{a_1, a_4\}$, $\{a_2, a_3, a_4\}$ w tym redukt minimalny – $\{a_1, a_4\}$

Redukty można efektywnie znajdować za pomocą różnych heurystyk, np. zachłanych.



Reguły

Warunek

Koniunkcja selektorów, każdy selektor reprezentuje test wartości pojedynczego atrybutu, warunek odpowiada obiektom spełniającym wszystkie selektory.

Decyzja

Każda reguła związana jest z jedną decyzją, przypisywaną obiektom spełniającym warunek reguły.

Przykład

$Wind = Weak \wedge Temp > 20 \wedge Outlook \neq Rain \Rightarrow PlayTennis = Yes$



Reguły: selektory

Atrybuty symboliczne:

- Selektor równościowy $X = v$
- Selektor wykluczający $X \neq v$
- Selektor ogólny $X \in \{v_1, \dots, v_k\}$

Atrybuty numeryczne:


- Selektor przedziałowy $X \in (a, b)$

Przedział może być jednostronnie nieograniczony, może też być jedno- lub obustronnie domknięty.



Reguły spójne

Reguła $\alpha \implies d = v$ jest spójna ze zbiorem treningowym U_{trn} jeśli każdy przykład $x \in U_{trn}$ spełniający warunek α ma decyzję $d(x) = v$.



Reguły spójne: przykład

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

$Outlook = Overcast \Rightarrow PlayTennis = Yes$

$Humidity = Normal \Rightarrow PlayTennis = Yes$

spójna
niespójna, bo D6 sprzeczne



Systemy regułowe: uczenie i klasyfikacja

Uczenie

Generowanie zbioru reguł na podstawie zbioru przykładów treningowych.

Klasyfikacja

Wyszukiwane są reguły pasujące do klasyfikowanego obiektu x , tzn. te, których warunek jest spełniany przez obiekt x , możliwe są dwie strategie podejmowania decyzji:

1. Najlepszy wygrywa:

regułom przypisana jest miara ważności *Importance*,
decyzja podejmowana jest na podstawie pasującej do x reguły r o najwyższej wartości $Importance(r)$

2. Głosowanie:

reguły mają przypisane wagi *Weight*,
obiekt x klasyfikowany jest decyzją o najwyższej sumie wag reguł pasujących
$$\max \arg_v \sum_{\alpha \Rightarrow d=v: x \text{ spełnia } \alpha} Weight(\alpha \Rightarrow d=v)$$



Generowanie reguł

Bezpośrednio ze zbioru przykładów

- zupełne
- sekwencyjne pokrywanie (CN2, AQ)

Przy użyciu struktur pośrednich

- z reduktu (teoria zbiorów przybliżonych)
- z drzewa decyzyjnego (C4.5rules)



Generowanie reguł z reduktu

$$Rules(R) := \left\{ \bigwedge_{a_i \in R} a_i = x_i \implies d = d(x) : x \in U_{trn} \right\}$$

Przykład:

	a_1	a_2	a_3	a_4	d
x_1	0	2	1	0	0
x_2	1	2	2	1	0
x_3	2	0	2	1	1
x_4	0	2	1	1	2

Redukt:

$$R = \{a_2, a_3, a_4\}$$

Reguły:

$$a_2 = 2 \wedge a_3 = 1 \wedge a_4 = 0 \implies d = 0$$

$$a_2 = 2 \wedge a_3 = 2 \wedge a_4 = 1 \implies d = 0$$

$$a_2 = 0 \wedge a_3 = 2 \wedge a_4 = 1 \implies d = 1$$

$$a_2 = 2 \wedge a_3 = 1 \wedge a_4 = 1 \implies d = 2$$



Skracanie reguł z reduktu

Skracanie reguły polega na odrzuceniu niektórych selektorów z warunku reguły.

Metoda

Reguła $\alpha \wedge s \implies d = v$ może zostać zastąpiona przez $\alpha \implies d = v$, jeśli $\alpha \implies d = v$ pozostaje spójna ze zbiorem treningowym.

Fakt

Może się zdarzyć, że różne reguły z tą samą decyzją zostaną skrócone do tej samej postaci

$\implies$ zbiór reguł po skróceniu może być mniejszy niż oryginalny.



Skracanie reguł z reduktu: przykład

	a_1	a_2	a_3	a_4	d
x_1	0	2	1	0	0
x_2	1	2	2	1	0
x_3	2	0	2	1	1
x_4	0	2	1	1	2

$$a_2 = 2 \wedge a_3 = 1 \wedge a_4 = 0 \implies d = 0$$

$$a_2 = 2 \wedge a_3 = 2 \wedge a_4 = 1 \implies d = 0$$

$$a_2 = 0 \wedge a_3 = 2 \wedge a_4 = 1 \implies d = 1$$

$$a_2 = 2 \wedge a_3 = 1 \wedge a_4 = 1 \implies d = 2$$

Po skróceniu:

$$a_2 = 2 \wedge a_4 = 0 \implies d = 0 \text{ lub } a_3 = 1 \wedge a_4 = 0 \implies d = 0$$

$$a_2 = 2 \wedge a_3 = 2 \implies d = 0$$

$$a_2 = 0 \implies d = 1$$


$$a_3 = 1 \wedge a_4 = 1 \implies d = 2$$



Generowanie reguł – zupełne


Fakt

Dla dowolnej reguły $s_1 \wedge \dots \wedge s_m \Rightarrow d$ wszystkie obiekty rozpoznawane przez nią rozpoznawane są także przez każdą regułę zbudowaną z podzbioru jej selektorów $s_{i_1} \wedge \dots \wedge s_{i_k} \Rightarrow d$



Generowanie reguł – zupełne

Wniosek: Obszar przestrzeni obiektów pokrywany przez wszystkie maksymalnie ogólne reguły spójne ($G_1, \dots, G_m$) jest taki sam jak obszar pokrywany przez wszystkie reguły spójne.




⇒ Wystarczy wyszukać wszystkie reguły spójne o minimalnym zbiorze selektorów, tzn. takim, że usunięcie dowolnego selektora daje regułę niespójną.



Generowanie reguł – zupełne

Jak to robić?

Można przeszukiwać przestrzeń wszystkich reguł zaczynając od reguł najbardziej ogólnych. Dopóki reguły nie są spójne ze zbiorem treningowym, są rozszerzane o selektory wykluczające przykłady powodujące ich niespójność.




Generowanie reguł – zupełne – przykład

Reguły z decyzją *PlayTennis* = Yes

candidates: *Outlook* = *Overcast* $\Rightarrow$ *PlayTennis* = Yes

Kontrprzykład: $\langle \textit{Overcast}, \textit{Cool}, \textit{Normal}, \textit{Weak}, \textit{PlayTennis} = \textit{No} \rangle$



Generowanie reguł – sekwencyjne pokrywanie

Generowanie reguł zupełne przegląda zazwyczaj wykładniczo dużą podprzestrzeń reguł, w praktyce niewykonalne.

Pomysł (heurystyczny): Reguły można generować pojedynczo do momentu pokrycia przez nie wszystkich obiektów treningowych.

```
function SEQUENTIAL-COVERING(examples) returns a rule set
  rules  $\leftarrow \{\}$ 
  uncovered  $\leftarrow$  examples
  repeat
    r  $\leftarrow$  LEARN-ONE-RULE(examples, uncovered)
    rules  $\leftarrow$  rules  $\cup$  r
    remove all examples covered by r from uncovered
  until uncovered is empty
  return rules
end function
```

Funkcja LEARN-ONE-RULE wyszukuje heurystycznie jak najlepszą regułę względem pewnej miary jakości reguł.



Dziękuję za uwagę!

- Data mining (1000-2M03DM)
- Eksploracja i przetwarzanie dużych zbiorów danych (1000-2M13DZD)
- Wnioskowanie aproksymacyjne (1000-1M00WA)
- Wyjaśnialne uczenie maszynowe (1000-1M18WUM)

